



Reconeixement òptic de música per a partitures de jazz

Sistema OMR d'extrem a extrem amb xarxes CRNN-CTC

Pol Casanovas Puig

Director: Manel Frigola Bourlon · Dept. de Control Automàtic

Grau en Enginyeria Informàtica — Computació

Facultat d'Informàtica de Barcelona · Universitat Politècnica de Catalunya

Juny de 2026


Com pot un ordinador
llegir una partitura?



Reconeixement òptic de música — com l'OCR, però per a partitures.

El problema: Partitures només en paper o imatge

- El *fake book* de jazz més estès del món
- Centenars d'estàndards; a tots els faristols
- El PDF oficial és només imatge
no es pot cercar, editar ni reproduir



Digitalitzar-lo desbloquejaria:

- Transposició automàtica (B $\flat$, E $\flat$, F)
- Reproducció MIDI per a l'estudi
- Anàlisi harmònica a escala de corpus
- Cerca i catalogació en biblioteques digitals

Quatre reptes

1 · Notació bidimensional

L'altura d'una nota depèn de la *posició relativa a la clau*; la durada, de cap + plica + corxets.

3 · Escassetat de dades

No hi ha cap corpus etiquetat de *lead sheets*. Cal construir dades sintètiques des de zero.

2 · Bretxa de domini

Models entrenats amb imatges netes fallen en escanejos reals: soroll, desenfocament, perspectiva, tinta.

4 · Doble flux

Melodia al pentagrama (patrons) + acords a sobre (text). Els sistemes existents només resolen el primer.

Pipeline d'inferència



Injecció de capçalera

Els pentagrames de continuació (no el primer) no tenen capçalera. S'hi afegeix una plantilla abans del CRNN de melodia → sempre veu un pentagrama complet.

Dos CRNN en paral·lel

Un model per a cada llenguatge visual: melodia (tokens LMX) i acords (caràcters).

Latència

114 ms per pàgina (8 pentagrames, RTX 3060, descodificació voraç).

Decisions de disseny

Per què CRNN-CTC?

Alternativa	Motiu de rebuig
Pipeline modular	Cal segmentació per símbol
Transformer (SMT, LEGATO)	Millor SER, però $>10\times$ còmput
Seq2seq + atenció	Sobrecàrrega sense benefici

Backbone: ResNet18 — meitat de temps que VGG.

Per què LMX?

✗ MusicXML

Arbre XML: cal context jeràrquic complet per a cada node.
Incompatible amb el flux atòmic del CTC.

✓ LMX


Tokens plans i atòmics: `pitch:C`, `quarter`, `flat`, `measure`.
Vocabulari ≈ 100 tokens · gramàtica regular → corrector determinista.

Dades sintètiques i simulació d'escaneig

- PrIMuS (87.678 incipits)
re-renderitzat en estil LilyJAZZ
- 3 filtres de domini → 46.089 mostres ·
≈166.000 imatges
- Partició 36.873 / 4.608 / 4.608 (train /
val / test)
- Simulació d'escaneig: soroll,
desenfocament, perspectiva, tinta,
esgrogueïment

Criteri d'acceptació

Bretxa net↔escanejat < 1 pp →
assolit: **0,06 pp**



The image displays four musical staves, each containing a single line of music in treble clef with a common time signature (C). The music consists of a sequence of notes and rests. The first staff, labeled 'Net (LilyJAZZ)', shows the original clean score. The subsequent three staves, labeled 'scaneig simulat 1', 'scaneig simulat 2', and 'scaneig simulat 3', show the same music after being processed with a scanning simulation. These simulated versions exhibit various visual artifacts such as noise, blurring, perspective distortion, and ink-like texture, which are highlighted by the orange borders around the staves.

Un error detectat i resultat: fuga de dades

Què passava:

1. `extra_data_dirs` afegia còpies derivades de mostres d'entrenament
2. S'unien al pool de splits abans de la partició aleatòria
3. Duplicats quasi-idèntics queien a val/test
4. Mètriques inflades (abans del 3 de juny de 2026)

Solució: `scanned_variant_dirs` — només train, indexat per ID de mostra.

Per què és un resultat positiu

Detectar la contaminació, redissenyar el protocol de splits i tornar a mesurar valida les xifres: totes les mètriques d'aquesta presentació són posteriors a la correcció.

Resultats principals

Mètrica	Escanejat	Net
SER agregat (%)	1,23	1,17
SER melòdic (%)	0,14	0,10
Transcripcions perfectes (%)	72,7	73,7

1,23 % < 3 %

objectiu assolit
(escaneig simulat)

99,86 %


de tokens de pitch, durada
i alteració correctes

0,06 pp

bretxa net↔escaneig
(criteri: < 1 pp)

On són els errors?

3.506 edicions · ≈90 % en barres de compàs i lligadures



- Pitch i octava quasi absents dels errors
- Les substitucions (errors de *contingut*) són només el 3,4 %

Conclusió

El model llegeix la música correctament; de tant en tant col·loca malament una barra. El SER melòdic (0,14 %) ho confirma.

Comparació qualitativa: Satin Doll

Audiveris 5.10 (referència lliure)

The Best (Back to 6)



- ✗ Clau correcta a 2 de 9 pentagrames
- ✗ Cap acord reconegut
- ✗ Octaves desplaçades → inservible

El nostre sistema



- ✓ 7 de 9 pentagrames, tots en clau de sol
- ✓ 36 acords (D-7 G7 · E-7 A7...)
- ✓ Títol i crèdits rebutjats correctament

Objectius assolits

- ✓ General — SER 1,23 % < 3 % (objectiu) en escaneig simulat
- ✓ O1 — Estat de l'art; CRNN-CTC justificat enfront de 3 alternatives
- ✓ O2 — Dataset sintètic LilyJAZZ des de PrIMuS (46.089 mostres)
- ✓ O3 — Simulació d'escaneig; bretxa net↔escaneig 0,06 pp
- ✓ O4 — CRNN-CTC: 1,17 % net / 1,23 % escanejat
- ✓ O5 — Anàlisi d'errors per categoria
- ✓ O6 — Pipeline complet + FastAPI + sortida JSON
- 🟡 O7 — Fine-tuning amb 36 staves reals: millora qualitativa;
sense SER real (totes calen per a entrenar)

Conclusions i treball futur

Què s'ha construït

- Sistema OMR d'extrem a extrem per a jazz
- SER agregat 1,23 % (escaneig simulat)
- SER melòdic 0,14 % — pitch quasi perfecte
- 72,7 % de transcripcions perfectes
- Acords: 5,9 % CER després del fine-tuning

Tres passos següents

1. Etiquetar ≥ 200 staves reals $\rightarrow$ SER de domini real (O7)
2. Vocabulari de tresets — el buit més gran de l'LMX
3. Detector de pentagrames après (YOLO/DETR) per a escanejos difícils

Aplicació directa: digitalització de *The Real Book* i transposició automàtica per a instruments en B $\flat$, E $\flat$ i F.

Competències tècniques (Computació)

CCO1.1 — Estratègies algorísmiques i rendiment

CRNN-CTC vs. seq2seq vs. transformer:
justificat per còmput i eficiència de dades.

Voraç vs. *beam search*: $<0,01$ pp de SER a
8x cost $\rightarrow$ voraç desplegat.

ResNet18 vs. VGG; corrector determinista vs.
après.

CCO2.4 — Aprenentatge automàtic i grans volums

CRNN-CTC supervisat amb pèrdua CTC.
 ≈ 166.000 imatges d'entrenament.

Pre-entrenament sintètic + fine-tuning de
domini als dos fluxos.

Fuga de dades detectada i corregida.

Totes dues competències declarades en profunditat a la inscripció del TFG.

Referències

- [1] J. Calvo-Zaragoza, D. Rizo. *End-to-end neural OMR of monophonic scores* (PrIMuS, CRNN-CTC). 2018.
- [2] OMR Research. *Linearized MusicXML (LMX)*. 2025.
- [3] J. Calvo-Zaragoza, D. Rizo. *Camera-PrIMuS dataset*. 2018.
- [4] A. Ríos-Vila et al. *Sheet Music Transformer (SMT / SMT++)*. 2024.
- [5] A. Graves et al. *Connectionist Temporal Classification*. 2006.
- [6] H. Bitteur. *Audiveris* (motor OMR de programari lliure), v5.10.

Gràcies



Preguntes?

SER	1,23 % escanejat / 1,17 % net (4.608 mostres)
SER melòdic	0,14 % — el pitch és quasi perfecte
Perfectes	72,7 % de pentagrames
Acords	5,9 % CER (de 69,9 % zero-shot)
Latència	114 ms/pàgina (RTX 3060)



Diapositives de suport

Suport · Corba d'entrenament



- SER cau de $\approx 12\%$ a $\approx 2\%$ cap a l'època 7
- Convergència a $\approx 1,2\%$ (època 83)
- 90 èpoques, ≈ 13 h en RTX 3060
- Plateau de validació: $\pm 0,02$ pp

Entrenament només amb escaneig simulat; les imatges netes es reserven per a l'avaluació.

Suport · Reconeixement d'acords

Condicció	Checkpoint	CER (%)	Exacte (%)	Strips
Val. sintètica	pre-entrenat	0,0	100,0	2000
Real, zero-shot	pre-entrenat	69,9	0,0	29
Real held-out	fine-tune	5,9	58,6	29

El flux d'acords col·lapsa en zero-shot sobre escanejos reals (glifs estilitzats + soroll de pàgina). El fine-tuning amb 262 strips reals tanca gairebé tota la bretxa.

Suport · Latència d'inferència

Etapa	Temps (ms)
Preprocés (càrrega + desbiaix + binarització)	21,0
Detecció de pentagrames	48,1
CRNN melodia (8 pentagrames, voraç)	7,6
CRNN acords (8 strips)	4,6
Corrector gramatical	0,1
Extrem a extrem (mediana, 10 reps.)	114,0

Pàgina representativa de 8 pentagrames, RTX 3060, descodificació voraç.

Suport · El pitjor cas melòdic



Entrada — pentagrama escanejat (mostra 220014195-1_1_1)



Ground truth — transcripció correcta



Predicció — l'última mesura és incorrecta

SER melòdic 0,092: les tres primeres mesures coincideixen; a l'última el model erra els tons (CCDD → BAEB). Els errors melòdics visibles són poc freqüents.