



Reconeixement òptic de música per a partitures de jazz

Sistema OMR d'extrem a extrem amb xarxes CRNN-CTC

Pol Casanovas Puig

Director: Manel Frigola Bourlon · Dept. de Control Automàtic

Grau en Enginyeria Informàtica — Computació

Facultat d'Informàtica de Barcelona · Universitat Politècnica de Catalunya

Juny de 2026

Com pot un ordinador
llegir una partitura?




Reconeixement òptic de música — com l'OCR, però per a partitures.

El problema: partitures només en paper o imatge

- Molta música notada només existeix en paper o escanejada
- Centenars d'estàndards de jazz, a tots els faristols
- Els PDF són només imatge
no es poden cercar, editar ni reproduir

Digitalitzar-la desbloquejaria:

- Transposició automàtica (B $\flat$, E $\flat$, F)
- Reproducció MIDI
- Anàlisi harmònica de corpus
- Cerca i catalogació



Quatre reptes

1 · Notació bidimensional

Altura = posició relativa a la clau;
durada = cap + plica + corxets.

3 · Escassetat de dades

Cap corpus etiquetat de *lead sheets* →
cal generar dades sintètiques.

2 · Bretxa de domini

Entrenat en net, falla en escanejos reals:
soroll, perspectiva, tinta.

4 · Doble flux

Melodia (pentagrama) + acords (text).
L'estat de l'art només fa el primer.

Pipeline d'inferència



Injecció de capçalera

Els pentagrames de continuació (no el primer) no tenen capçalera. S'hi afegeix una plantilla abans del CRNN de melodia → sempre veu un pentagrama complet.

Dos CRNN en paral·lel

Un model per a cada llenguatge visual: melodia (tokens LMX) i acords (caràcters).

Latència

114 ms per pàgina (8 pentagrames, RTX 3060, descodificació voraç).

Decisions de disseny

Per què CRNN-CTC?

Alternativa	Motiu de rebuig
Pipeline modular	Cal segmentació per símbol
Transformer (SMT, LEGATO)	Millor SER, però $>10\times$ còmput
Seq2seq + atenció	Sobrecàrrega sense benefici

Backbone: ResNet18 — meitat de temps que VGG.

Per què LMX?

✗ MusicXML

Arbre XML jeràrquic → incompatible amb el flux atòmic del CTC.

✓ LMX

Tokens plans i atòmics: `pitch:C`, `quarter`, `flat`, `measure`.
Vocabulari ≈ 100 tokens · gramàtica regular → corrector determinista.


Dades sintètiques i simulació d'escaneig

- PrIMuS (87.678 incipits)
re-renderitzat en estil LilyJAZZ
- 3 filtres de domini → 46.089 mostres ·
≈166.000 imatges
- Partició 36.873 / 4.608 / 4.608 (train /
val / test)
- Escaneig simulat: soroll, perspectiva,
tinta, esgrogueïment


Criteri d'acceptació

Bretxa net↔escanejat < 1 pp →
assolit: **0,06 pp**

Net (LilyJAZZ)



Escaneig simulat 1



Escaneig simulat 2



Escaneig simulat 3



Resultats principals

Mètrica	Escanejat	Net
SER agregat (%)	1,23	1,17
SER melòdic (%)	0,14	0,10
Transcripcions perfectes (%)	72,7	73,7

1,23 % < 3 %

objectiu assolit
(escaneig simulat)

99,86 %


de tokens de pitch, durada
i alteració correctes

0,06 pp

bretxa net↔escaneig
(criteri: < 1 pp)

On són els errors?

3.506 edicions · ≈90 % en barres de compàs i lligadures



- Pitch i octava quasi absents dels errors
- Les substitucions (errors de *contingut*) són només el 3,4 %

Conclusió

El model llegeix la música correctament; de tant en tant col·loca malament una barra. El SER melòdic (0,14 %) ho confirma.

Comparació qualitativa: Satin Doll

Audiveris 5.10 (referència lliure)

The Best (Back in 6)



- ✗ Clau correcta a 2 de 9 pentagrames
- ✗ Cap acord reconegut
- ✗ Octaves desplaçades → inservible

El nostre sistema



D-7 G-7 D-7 G7 E-7 A7
E-7 A7 A-7 D7 Ab-7 Db7
E-7b5 A7b9 D-7 E-7
G-7 C7 Fmaj7 G-7 C7
A-7 D7 D-7 G7 E-7 A7
D-7 G7 E-7 A7
A-7 D7 Ab-7 Db7 C-7b5

- ✓ 7 de 9 pentagrames, tots en clau de sol
- ✓ 36 acords (D-7 G7 · E-7 A7...)
- ✓ Títol i crèdits rebutjats correctament

Objectius assolits

- ✓ General — SER 1,23 % < 3 % (objectiu) en escaneig simulat
- ✓ O1 — Estat de l'art; CRNN-CTC justificat enfront de 3 alternatives
- ✓ O2 — Dataset sintètic LilyJAZZ des de PrIMuS (46.089 mostres)
- ✓ O3 — Simulació d'escaneig; bretxa net↔escaneig 0,06 pp
- ✓ O4 — CRNN-CTC: 1,17 % net / 1,23 % escanejat
- ✓ O5 — Anàlisi d'errors per categoria
- ✓ O6 — Pipeline complet + FastAPI + sortida JSON
- 🟡 O7 — Fine-tuning amb 36 pentagrames reals: millora qualitativa; sense SER real (totes calen per a entrenar)

Conclusions i treball futur

Què s'ha construït

- Sistema OMR d'extrem a extrem per a jazz
- SER agregat 1,23 % (escaneig simulat)
- SER melòdic 0,14 % — pitch quasi perfecte
- 72,7 % de transcripcions perfectes
- Acords: 5,9 % CER després del fine-tuning

Tres passos següents

1. Etiquetar ≥ 200 pentagrames reals
→ SER de domini real (O7)
2. Vocabulari de tresets — el buit més gran de l'LMX
3. Detector de pentagrames après (YOLO/DETR) per a escanejos difícils

Aplicació directa: digitalització de *The Real Book* i transposició automàtica per a instruments en B $\flat$, E $\flat$ i F.

Competències tècniques (Computació)

CCO1.1 — Estratègies algorísmiques i rendiment

CRNN-CTC vs. transformer: triat per còmput i eficiència de dades.

Voraç vs. *beam*: $<0,01$ pp a $8\times$ cost.

ResNet18 vs. VGG; corrector determinista.

CCO2.4 — Aprenentatge automàtic i grans volums

CRNN-CTC amb pèrdua CTC; ≈ 166.000 imatges.

Pre-entrenament sintètic + fine-tuning als dos fluxos.

Fuga de dades detectada i corregida.

Totes dues competències declarades en profunditat a la inscripció del TFG.

Referències

- [1] J. Calvo-Zaragoza, D. Rizo. *End-to-end neural OMR of monophonic scores* (PrIMuS, CRNN-CTC). 2018.
- [2] OMR Research. *Linearized MusicXML (LMX)*. 2025.
- [3] J. Calvo-Zaragoza, D. Rizo. *Camera-PrIMuS dataset*. 2018.
- [4] A. Ríos-Vila et al. *Sheet Music Transformer (SMT / SMT++)*. 2024.
- [5] A. Graves et al. *Connectionist Temporal Classification*. 2006.
- [6] H. Bitteur. *Audiveris* (motor OMR de programari lliure), v5.10.

Gràcies



Preguntes?

SER	1,23 % escanejat / 1,17 % net (4.608 mostres)
SER melòdic	0,14 % — el pitch és quasi perfecte
Perfectes	72,7 % de pentagrames
Acords	5,9 % CER (de 69,9 % zero-shot)
Latència	114 ms/pàgina (RTX 3060)



Diapositives de suport

Suport · Corba d'entrenament



- SER cau de $\approx 12\%$ a $\approx 2\%$ cap a l'època 7
- Convergència a $\approx 1,2\%$ (època 83)
- 90 èpoques, ≈ 13 h en RTX 3060
- Plateau de validació: $\pm 0,02$ pp

Entrenament només amb escaneig simulat; les imatges netes es reserven per a l'avaluació.

Suport · Reconeixement d'acords

Condicció	Checkpoint	CER (%)	Exacte (%)	Strips
Val. sintètica	pre-entrenat	0,0	100,0	2000
Real, zero-shot	pre-entrenat	69,9	0,0	29
Real held-out	fine-tune	5,9	58,6	29

El flux d'acords col·lapsa en zero-shot sobre escanejos reals (glifs estilitzats + soroll de pàgina). El fine-tuning amb 262 strips reals tanca gairebé tota la bretxa.

Suport · Latència d'inferència

Etapa	Temps (ms)
Preprocés (càrrega + desbiaix + binarització)	21,0
Detecció de pentagrames	48,1
CRNN melodia (8 pentagrames, voraç)	7,6
CRNN acords (8 strips)	4,6
Corrector gramatical	0,1
Extrem a extrem (mediana, 10 reps.)	114,0

Pàgina representativa de 8 pentagrames, RTX 3060, descodificació voraç.

Suport · Un cas melòdic difícil



Entrada — pentagrama escanejat (mostra 220014195-1_1_1)



Ground truth — transcripció correcta



Predicció — confusió d'octava en notes greus

SER melòdic 0,089 (rang 3 dels pitjors casos): el model confon l'octava d'algunes notes greus en patrons de semicorxera. Els errors melòdics visibles són poc freqüents.