



Reconeixement òptic de música per a partitures de jazz

Sistema OMR d'extrem a extrem amb xarxes CRNN-CTC

Pol Casanovas Puig

Director: Manel Frigola Bourlon · Dept. de Control Automàtic

Grau en Enginyeria Informàtica — Computació

Facultat d'Informàtica de Barcelona · Universitat Politècnica de Catalunya

Juny de 2026

Com pot un ordinador
llegir una partitura?




Reconeixement òptic de música — com l'OCR, però per a partitures.

El problema: partitures només en paper o imatge

- Molta música notada només existeix en paper o escanejada
- Centenars d'estàndards de jazz, a tots els faristols
- Els PDF són només imatge
no es poden cercar, editar ni reproduir

Digitalitzar-la desbloquejaria:

- Transposició automàtica (B $\flat$, E $\flat$, F)
- Reproducció MIDI
- Anàlisi harmònica de corpus
- Cerca i catalogació



Quatre reptes

1 · Notació bidimensional

Altura = posició relativa a la clau;
durada = cap + plica + corxets.

3 · Escassetat de dades

Cap corpus etiquetat de *lead sheets* →
cal generar dades sintètiques.

2 · Bretxa de domini

Entrenat en net, falla en escanejos reals:
soroll, perspectiva, tinta.

4 · Doble flux

Melodia (pentagrama) + acords (text).
L'estat de l'art només fa el primer.

Pipeline d'inferència



Injecció de capçalera

Els pentagrames de continuació (no el primer) no tenen capçalera. S'hi afegeix una plantilla abans del CRNN de melodia → sempre veu un pentagrama complet.

Dos CRNN en paral·lel

Un model per a cada llenguatge visual: melodia (tokens LMX) i acords (caràcters).

Latència

114 ms per pàgina (8 pentagrames, RTX 3060, descodificació voraç).

Decisions de disseny

Per què CRNN-CTC?

Alternativa	Motiu de rebuig
Pipeline modular	Cal segmentació per símbol
Transformer (SMT, LEGATO)	Millor SER, però $>10\times$ còmput
Seq2seq + atenció	Sobrecàrrega sense benefici

Backbone: ResNet18 — meitat de temps que VGG.

Per què LMX?

✗ MusicXML

Arbre XML jeràrquic → incompatible amb el flux atòmic del CTC.

✓ LMX

Tokens plans i atòmics: `pitch:C`, `quarter`, `flat`, `measure`.
Vocabulari ≈ 100 tokens · gramàtica regular → corrector determinista.


Dades sintètiques i simulació d'escaneig

- PrIMuS (87.678 incipits)
re-renderitzat en estil LilyJAZZ
- 3 filtres de domini → 46.089 mostres ·
≈166.000 imatges
- Partició 36.873 / 4.608 / 4.608 (train /
val / test)
- Escaneig simulat: soroll, perspectiva,
tinta, esgrogueïment


Criteri d'acceptació

Bretxa net↔escanejat < 1 pp →
assolit: **0,06 pp**

Net (LilyJAZZ)




escaneig simulat 1



escaneig simulat 2



escaneig simulat 3



Resultats principals

Mètrica	Escanejat	Net
SER agregat (%)	1,23	1,17
SER melòdic (%)	0,14	0,10
Transcripcions perfectes (%)	72,7	73,7

1,23 % < 3 %

objectiu assolit
(escaneig simulat)

99,86 %


de tokens de pitch, durada
i alteració correctes

0,06 pp

bretxa net↔escaneig
(criteri: < 1 pp)

On són els errors?

3.506 edicions · ≈90 % en barres de compàs i lligadures



- Pitch i octava quasi absents dels errors
- Les substitucions (errors de *contingut*) són només el 3,4 %

Conclusió

El model llegeix la música correctament; de tant en tant col·loca malament una barra. El SER melòdic (0,14 %) ho confirma.

Comparació qualitativa: Satin Doll

Audiveris 5.10 (referència lliure)

The Best (Back in 6)



- ✗ Clau correcta a 2 de 9 pentagrames
- ✗ Cap acord reconegut
- ✗ Octaves desplaçades → inservible

El nostre sistema



- ✓ 7 de 9 pentagrames, tots en clau de sol
- ✓ 36 acords (D-7 G7 · E-7 A7...)
- ✓ Títol i crèdits rebutjats correctament

Demostració del sistema

D'una pàgina escanejada del *Real Book* a la transcripció simbòlica, d'extrem a extrem.

Preprocés → detecció de pentagrames → CRNN de melodia i acords en paral·lel → corrector gramatical → JSON.

▶ Veure la demostració



youtu.be/JAkTSFvwVQ4

Objectius assolits

- ✓ General — SER 1,23 % < 3 % (objectiu) en escaneig simulat
- ✓ O1 — Estat de l'art; CRNN-CTC justificat enfront de 3 alternatives
- ✓ O2 — Dataset sintètic LilyJAZZ des de PrIMuS (46.089 mostres)
- ✓ O3 — Simulació d'escaneig; bretxa net↔escaneig 0,06 pp
- ✓ O4 — CRNN-CTC: 1,17 % net / 1,23 % escanejat
- ✓ O5 — Anàlisi d'errors per categoria
- ✓ O6 — Pipeline complet + FastAPI + sortida JSON
- 🟡 O7 — Fine-tuning amb 36 pentagrames reals: millora qualitativa; sense SER real (totes calen per a entrenar)

Conclusions i treball futur

Què s'ha construït

- Sistema OMR d'extrem a extrem per a jazz
- SER agregat 1,23 % (escaneig simulat)
- SER melòdic 0,14 % — pitch quasi perfecte
- 72,7 % de transcripcions perfectes
- Acords: 5,9 % CER després del fine-tuning

Tres passos següents

1. Etiquetar ≥ 200 pentagrames reals
→ SER de domini real (O7)
2. Vocabulari de tresets — el buit més gran de l'LMX
3. Detector de pentagrames après (YOLO/DETR) per a escanejos difícils

Aplicació directa: digitalització de *The Real Book* i transposició automàtica per a instruments en B $\flat$, E $\flat$ i F.

Competències tècniques (Computació)

CCO1.1 — Estratègies algorísmiques i rendiment

CRNN-CTC vs. transformer: triat per còmput i eficiència de dades.

Voraç vs. *beam*: $<0,01$ pp a $8\times$ cost.

ResNet18 vs. VGG; corrector determinista.

CCO2.4 — Aprenentatge automàtic i grans volums

CRNN-CTC amb pèrdua CTC; ≈ 166.000 imatges.

Pre-entrenament sintètic + fine-tuning als dos fluxos.

Fuga de dades detectada i corregida.

Totes dues competències declarades en profunditat a la inscripció del TFG.

Referències

- [1] J. Calvo-Zaragoza, D. Rizo. *End-to-end neural OMR of monophonic scores* (PrIMuS, CRNN-CTC). 2018.
- [2] OMR Research. *Linearized MusicXML (LMX)*. 2025.
- [3] J. Calvo-Zaragoza, D. Rizo. *Camera-PrIMuS dataset*. 2018.
- [4] A. Ríos-Vila et al. *Sheet Music Transformer (SMT / SMT++)*. 2024.
- [5] A. Graves et al. *Connectionist Temporal Classification*. 2006.
- [6] H. Bitteur. *Audiveris* (motor OMR de programari lliure), v5.10.

Gràcies



Preguntes?

SER	1,23 % escanejat / 1,17 % net (4.608 mostres)
SER melòdic	0,14 % — el pitch és quasi perfecte
Perfectes	72,7 % de pentagrames
Acords	5,9 % CER (de 69,9 % zero-shot)
Latència	114 ms/pàgina (RTX 3060)



Diapositives de suport

Suport · Corba d'entrenament



- SER cau de $\approx 12\%$ a $\approx 2\%$ cap a l'època 7
- Convergència a $\approx 1,2\%$ (època 83)
- 90 èpoques, ≈ 13 h en RTX 3060
- Plateau de validació: $\pm 0,02$ pp

Entrenament només amb escaneig simulat; les imatges netes es reserven per a l'avaluació.

Suport · Reconeixement d'acords

Condicció	Checkpoint	CER (%)	Exacte (%)	Strips
Val. sintètica	pre-entrenat	0,0	100,0	2000
Real, zero-shot	pre-entrenat	69,9	0,0	29
Real held-out	fine-tune	5,9	58,6	29

El flux d'acords col·lapsa en zero-shot sobre escanejos reals (glifs estilitzats + soroll de pàgina). El fine-tuning amb 262 strips reals tanca gairebé tota la bretxa.

Suport · Latència d'inferència

Etapa	Temps (ms)
Preprocés (càrrega + desbiaix + binarització)	21,0
Detecció de pentagrames	48,1
CRNN melodia (8 pentagrames, voraç)	7,6
CRNN acords (8 strips)	4,6
Corrector gramatical	0,1
Extrem a extrem (mediana, 10 reps.)	114,0

Pàgina representativa de 8 pentagrames, RTX 3060, descodificació voraç.

Suport · Un cas melòdic difícil



Entrada — pentagrama escanejat (mostra 220014195-1_1_1)



Ground truth — transcripció correcta



Predicció — confusió d'octava en notes greus

SER melòdic 0,089 (rang 3 dels pitjors casos): el model confon l'octava d'algunes notes greus en patrons de semicorxera. Els errors melòdics visibles són poc freqüents.

Suport · Arquitectura del model (CRNN-CTC)

- Entrada: pentagrama d'1 canal, alçada fixa 128 px, amplada variable (límit 2048 px)
- Backbone ResNet18 (sense ImageNet): conv1 7×7 monocanal; passes asimètriques → alçada ÷32, amplada ÷4
- AdaptiveAvgPool → ($W/4$, B , 512)
- BiLSTM 2 capes, 256/direcció (512), dropout 0,3
- Linear → 80 classes → `log_softmax`
- `CTCLoss(blank=0, zero_infinity)`

Xifres

≈ 14,4 M paràmetres

Descodificació voraç
(*beam* < 0,01 pp a 8× cost)

AdamW 1e-3 · OneCycle · *batch* 16 ·
≈ 8,5 GB VRAM

Vocabulari = 80 (77 tokens LMX +
blank/pad/unk). Entrenat des de zero.

Suport · LMX: gramàtica i exemple

Ordre dels tokens d'una nota

`pitch:<A--G> · octave:<0--8> · durada · dot* · [alteració] · [tied:stop] · [fermata]`

- L'alteració és una paraula simple (`flat/sharp/natural`) després de la durada; és només visual (el to ja és a `pitch`)
- El compàs són 3 tokens: `time · beats:N · beat-type:N` → comparteix representació entre mètriques

Exemple — 3/4 en Mib major

```
measure clef:G2 key:fifths:-3 time beats:3 beat-type:4
```

```
pitch:B octave:5 quarter flat   pitch:E octave:5 eighth flat ...
```

Suport · Higiene de dades: fuga i correcció

Què va fallar

- Variants derivades d'una mateixa peça (bessones sense capçalera, re-renders, augmentacions) entraven al conjunt abans de la partició aleatòria
- Un quasi-duplicat de *train* podia caure a *val/test* → mètriques inflades

Mètriques pre-correcció — invàlides

0,23 % SER · 94,1 % perfectes (no comparables).

La correcció

- Partició per id de mostra: totes les variants (neta + escanejades) al mateix costat
- Diversitat només a *train* per construcció — no pot creuar el *split*
- Totes les xifres reportades són posteriors a la correcció (run 20260612, època 83)

Detectat i corregit a mig projecte → evidència d'autocorrecció i d'higiene de dades.

Suport · SER brut vs. contingut

- SER agregat 1,23 % = sortida crua del CRNN, abans del corrector i sobre pentagrames aïllats → els errors estructurals compten en contra, no s'amaguen.
- SER melòdic 0,14 % = distància d'edició ignorant barres de compàs i lligadures (només contingut).
- El corrector gramatical re-barreja a partir del compàs → una barra mal col·locada poques vegades canvia el contingut renderitzat.

Per què dues xifres

Es mantenen totes dues a la taula perquè el tribunal pugui jutjar l'error total i el de contingut per separat, sense dependre del nostre enquadrament.

Suport · Gestió i metodologia

Metodologia

Iterativa i incremental; sprints de 4 setmanes alineats amb els *work packages*; reunions quinzenals amb el director.

Bucle tancat dades → entrenament → anàlisi d'errors: cada error sistemàtic dispara un canvi de *pipeline* i un reentrenament.

Replanificacions

- Sprints GEP de 2 set. → 4 set./WP
- Flux d'acords afegit tard, absorbit sense ampliar pressupost

Work package	h
WP0 Gestió (transversal)	130
WP1 Estat de l'art	78
WP2 Dades	73
WP3 CRNN-CTC	75
WP4 Refinement	68
WP5 Avaluació + defensa	85
Total	509

$21 \text{ setmanes} \cdot 31 \text{ tasques} \cdot 509 \text{ h} < 540 \text{ h (Art. 17)} \rightarrow 31 \text{ h de reserva. Risc: 6 riscos (probabilitat} \times \text{impacte) amb disparadors; control per valor guanyat.}$

Suport · Pressupost

Concepte	€
Recursos humans ($\approx 85\%$)	13.615,57
Costos generals	250,69
Contingència (15 %)	2.079,94
Imprevistos (risc)	150,96
Total	16.097,16

- 509 h de feina · tarifa mitjana 26,75 €/h
- Maquinari (RTX 3060) amortitzat: 125,69 €
- Programari: **0 €** — tota la cadena és codi obert
- El cost dominant és el temps d'enginyeria

Suport · Sostenibilitat

Ambiental

- **≈62,5 kWh** tot el projecte
- **≈14,4 kg** CO₂e (0,23 kg/kWh, xarxa ES)
- Mitigació: ResNet18, precisió mixta, *early stopping*, reús de maquinari

Econòmica

- 100 % codi obert (0 € de llicències)
- Corre en maquinari de consum (1 GPU)
- Menor cost per pàgina que l'OMR comercial

Social

- Beneficia músics, docents, arxivers, recerca
- JSON → accessible (lectors de pantalla, braille)
- Exclou: polifonia, claus no-sol, estils fora del Real Book

ODS: 4 Educació · 9 Indústria i innovació · 10 Reducció de desigualtats · 12 Consum responsable

Suport · Aspectes legals i propietat intel·lectual

The Real Book — © Hal Leonard

- El CRNN de melodia s'entrena només amb dades sintètiques (LilyJAZZ); cap pàgina amb drets és entrada d'entrenament
- Els escanejos reals: només avaluació i un petit *fine-tuning* d'acords; mai redistribuïts
- Els pesos alliberats codifiquen tokens, no píxels

Base legal

RD Leg. 1/1996 art. 32 (docència i recerca)
+ Directiva UE 2019/790 art. 3 (mineria de text i dades).

- PrIMuS: PRAIG / Univ. d'Alacant, recerca no comercial; sense modificar
- RGPD (2016/679) no aplica: cap dada personal
- El llançament exclou tot material derivat del Real Book